PROJET RÉALISÉ PAR

L'ÉQUIPE GBSC DU GROUPE DE TD2

RAPPORT DE GROUPE DES UE BASES DE DONNÉES + SCIENCES DES DONNÉES 2

Kardiatou BA, Lea Carminati, Diella Joannie GATEKA, Lana SCHEMBRI.

Département MIASHS, UFR 6 Informatique, Mathématique et Statistique
Université Paul Valéry, Montpellier 3

Avril 2025

Soumis comme contribution partielle
pour le cours Science des données 2 et Bases de données

Déclaration de non plagiat

À compléter avant la remise du rapport.

Nous déclarons que ce rapport est le fruit de notre seul travail, à part lorsque cela est indiqué explicitement.

Nous acceptons que la personne évaluant ce rapport puisse, pour les besoins de cette évaluation :

- la reproduire et en fournir une copie à un autre membre de l'université ; et/ou,
- en communiquer une copie à un service en ligne de détection de plagiat (qui pourra en retenir une copie pour les besoins d'évaluation future).

Nous certifions que nous avons lu et compris les règles ci-dessus.

En signant cette déclaration, nous acceptons ce qui précède.

Signature : _____ Date : _____

Signature : _____ Date : _____

Signature : _____ Date : _____

Signature : _____ Date : _____

29 avril 2025

Remerciements

À compléter avant la remise du rapport.

Nous adressons nos plus sincères remerciements à nos encadrantes pédagogiques, Mme Bringay et Mme Demangeot, pour leurs précieux conseils, leur soutien constant et leur disponibilité tout au long de la réalisation de notre projet. Leur expertise a été essentielle pour le bon déroulement et le développement de notre travail.
Nous leur sommes profondément reconnaissantes pour le temps et l'énergie qu'elles ont consacrés à notre accompagnement, ainsi que pour la passion avec laquelle elles nous ont transmis leurs connaissances

29 avril 2025

Résumé

Nous sommes perpétuellement à la recherche du confort, de la tranquillité, d'une meilleure qualité de vie en général. Cela peut passer par le choix du département dans lequel on souhaite vivre, dans l'espoir de s'y épanouir pleinement. On a souvent tendance à penser que des revenus élevés, à l'échelle territoriale, sont synonymes de confort. Mais est-ce réellement le cas ?
Notre rapport s'intéresse particulièrement aux départements français. Pour évaluer la qualité de vie qu'ils offrent, il nous a semblé pertinent d'analyser une série d'indicateurs : des indicateurs socio-économiques, tels que le taux de chômage et le taux de pauvreté ; socio démographiques et structurels, comme la densité de population, le nombre d'habitants, le nombre total de logements et le taux de logements sociaux ; et enfin, des indicateurs culturels, comme le nombre d'établissements culturels par département.
Le choix du département où l'on souhaite vivre parviendra-t-il à satisfaire toutes nos attentes ? Après une étude approfondie de nos données, nous avons pu constater que des revenus moyens élevés ne garantissent pas forcément de meilleures conditions de vie. Certains départements affichant des revenus salariaux élevés présentent également des taux de chômage et de pauvreté non négligeables, une forte densité de population et un grand nombre d'établissements culturels, mais aussi des risques accrus de saturation des services publics. On y observe souvent des inégalités sociales marquées, avec la coexistence de zones très favorisées et d'autres en grande précarité, sans oublier un taux de logements sociaux souvent insuffisant face à la demande.
À l'inverse, certains départements économiquement moins favorisés offrent parfois un cadre de vie plus équilibré : faible densité, pauvreté modérée et bonne accessibilité aux infrastructures culturelles.
D'ailleurs, pour appuyer nos propos, des tests statistiques de corrélation ont permis de rejeter l'hypothèse d'une relation significative entre le niveau de revenu salarial et les taux de chômage ou de pauvreté.
Étant donné que le test d'ANOVA montre que le revenu moyen d'un département à un effet significatif sur le nombre d'établissements culturels.
Ainsi, ce rapport met en lumière la complexité des dynamiques territoriales et la nécessité de dépasser les simples critères économiques pour penser la qualité de vie.

Table des matières

Chapitre 1 Introduction 1
1.1 Responsabilités et composition de l'équipe 1

Chapitre 2 Base de données 2
2.1 Provenance des données 2
2.2 Descriptif des tables 2
2.3 Modèles MCD et MOD 4
2.4 Import des données 5
2.5 Requêtes réalisées 6

Chapitre 3 Matériel et Méthodes 12
3.1 Logiciels 12
3.2 Modélisation statistique 12
3.2.1 Le test de corrélation de Pearson 13
3.2.2 Analyse de la variance 13

Chapitre 4 Analyse Exploratoire des Données 14
4.1 Import des fichiers csv utiles aux analyses statistiques 14
4.2 Analyses univariées 14
4.3 Analyses bivariées 16
4.4 Test d'ANOVA 20

Chapitre 5 Discussion 22

Chapitre 6 Conclusion 23
6.1 Perspectives 23
6.2 Difficultés 24

Bibliographie 25

Annexes 26
Codes 27

Chapitre 1

Introduction

La qualité de vie est influencée par de nombreux facteurs, comme par exemple les facteurs économiques, la répartition démographique et les services publics. Quand on évalue le bien-être d'une population, on pourrait penser qu'un revenu moyen élevé garantit de meilleures conditions de vie. Cependant cette corrélation n'est pas évidente : certains départements riches peuvent être confrontés à des problématiques telles que des coûts de logements élevés, ou une forte densité de population, tandis que d'autres, avec des revenus plus bas, peuvent s'offrir un cadre de vie plus équilibré. Dès lors, nous pouvons nous poser les questions suivantes :

Les départements français offrants les meilleures conditions de vie sont-ils nécessairement ceux avec les revenus moyens les plus élevés ? Et ces départements se démarquent-ils du lot avec des infrastructures culturelles plus nombreuses et avec moins de logements sociaux ?

Ces questions nous aident à comprendre les dynamiques entre revenu, salaire, logement sociaux, nombre d'établissements culturels (cinéma, théâtre, musée, etc) et bien-être social. En répondant à cette problématique, nous pourrons identifier les critères qui définissent une bonne qualité de vie. Comprendre ces dynamiques peut être utile aux citoyens pour faire des choix de résidences plus conscientes, aux politiques d'investissement et aménagement pour mieux s'orienter. Cette analyse pourrait ainsi favoriser un développement territorial plus équilibré et sensibiliser aux déterminants de la qualité de vie. En croisant les données économiques et sociales, cette étude propose une lecture plus nuancée des disparités sociales en France.

1.1 Responsabilités et composition de l'équipe

Kardiatou BA : Étudiant n° 22310777, Responsable de la collecte, manipulation des données, rapport et de la partie base de données.

Lea CARMINATI Étudiant n° 22307644, Responsable rapport et de la partie statistique.

Diella Joannie GATEKA : Étudiant n° 22311183, Responsable de la collecte, manipulation des données,rapport et de la partie base de données.

Lana SCHEMBRI : Étudiant n° 22313116, Responsable rapport de la partie statistique.

Chapitre 2

Base de données

2.1 Provenance des données

Voici les sources de données utilisées pour notre travail :

Source de données 1 :

https://www.data.gouv.fr/fr/datasets/limpot-sur-le-revenu-par-collectivite-territoriale-ircom/ (format xlsx,12 colonnes et 1897 lignes).

Ce premier jeu de données fournit des informations sur les revenus des personnes vivant en France, réparties par département, sur la période de 2000 à 2017.

Source de données 2 :

https://www.data.gouv.fr/fr/datasets/logements-et-logements-sociaux-dans-les-departements-1/ (format csv, 34 colonnes et 601 lignes).

Ce deuxième jeu de données permet d'analyser l'évolution des territoires, l'activité de la construction et le secteur du logement social. Il comprend également plusieurs indicateurs utiles pour évaluer la qualité de vie dans les départements.

Source de données 3 :

https://www.data.gouv.fr/fr/datasets/entreprises-nombre-detablissements-culturels-actifs-par-departement/ (format csv, 101 lignes et 5 colonnes).

Ce troisième jeu de données renseigne sur le nombre total d'établissements culturels présents dans chaque département depuis 2022. Il indique également, d'une part, le nombre d'établissements culturels construits en 2018, et d'autre part, la part que ces établissements représentent.

La population étudiée correspond aux ménages français, répartis par département, avec une distinction entre salariés et retraités. Les données permettent d'analyser les disparités économiques et sociales entre les territoires. Les revenus fournissent une vision des écarts financiers, tandis que le chômage, la pauvreté et les logements permettent d'évaluer la qualité de vie socio-économique. Les unités statistiques sont les départements français. Ils offrent une échelle d'analyse pour comparer les dynamiques sociales et économiques du pays.

2.2 Descriptif des tables

Voici les tables conservées après filtrage :

Table 2.1: Departement (101 × 13)

Nom colonne	Type	Signification	Caractéristique
code_dep	integer	code departement	clé primaire
nom_dep	varchar	nom departement	
code_region	integer	code region	clé étrangère
nbr_hab	integer	nombre habitants departement	
densite	double	densite habitants departement	
pourcpopvingt	double	pourcentage population 20 ans	
pourpopsoixante	double	pourcentage population 60 ans	
taux_chomage	double	taux de chômage departement	
taux_pauvrete	double	taux pauvrete departement	
nbr_foyer_salarie	integer	nombre des foyers salariés departement	
montant_salairie	double	montant des salaires	
nbr_foyer_retraite	integer	nombre des foyers retraités	
montant_retraite	double	montant des retraites	

Table 2.2: Region (18 × 2)

Nom colonne	Type	Signification	Caractéristique
code_region	integer	code region	clé primaire
nom_region	varchar	nom region	unique

Table 2.3: Etablissement (101 × 4)

Nom colonne	Type	Signification	Caractéristique
id_eta	integer	identifiant etablissement	clé primaire
code_dep	integer	code departement	clé étrangère
nbr_t_eta	integer	nombre total établissements culturels	
nbr_eta_2018	integer	nombre établissements construit en 2018	

Table 2.4: Logement (101 × 5)

Nom colonne	Type	Signification	Caractéristique
id_log	integer	identifiant logement	clé primaire
code_dep	integer	code departement	clé étrangère
nbr_log	integer	nombre total logements sociaux	
nbr_eta_2018	integer	nombre logements sociaux	
taux_log_sociaux	float	taux de logements sociaux	
taux_log_ind	float	taux logements individuels	

Nom colonne	Type	Signification	Caractéristique

2.3 Modèles MCD et MOD

— Pour le MCD, on inclut une image réalisée avec le logiciel Mocodo [https://www.mocodo.net/] visible sur la Figure 2.1 ci-dessous :

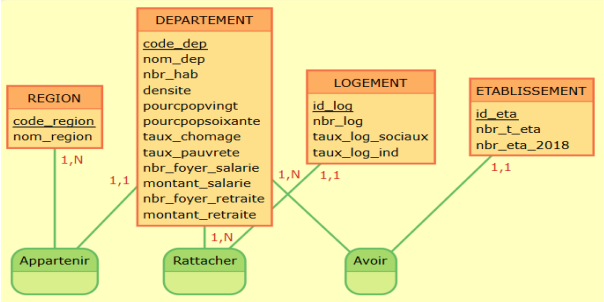

FIGURE 2.1: MCD.

— A partir de ce modèle conceptuel(MCD), nous avons crée la version manuscrite de notre Modèle Organisationnel de Données(MOD) :

DEPARTEMENT (code_dep, nom_dep, nbr_hab, densite, pourcpopvingt, pourcpopsoixante, taux_chomage, taux_pauvrete,nbr_foyer_salarie, montant_salarie, nbr_foyer_retraite, montant_retraite, code_region)

REGION (code_region, nom_region)

LOGEMENT (id_log, nbr_log, taux_log_sociaux, taux_log_ind, code_dep)

ETABLISSEMENT (id_eta, nbr_t_eta, nbr_eta_2018, code_dep)

Pour le MOD, on inclut une image réalisée avec le designer de phpmyadmin, visible sur la Figure 2.2 ci-dessous :

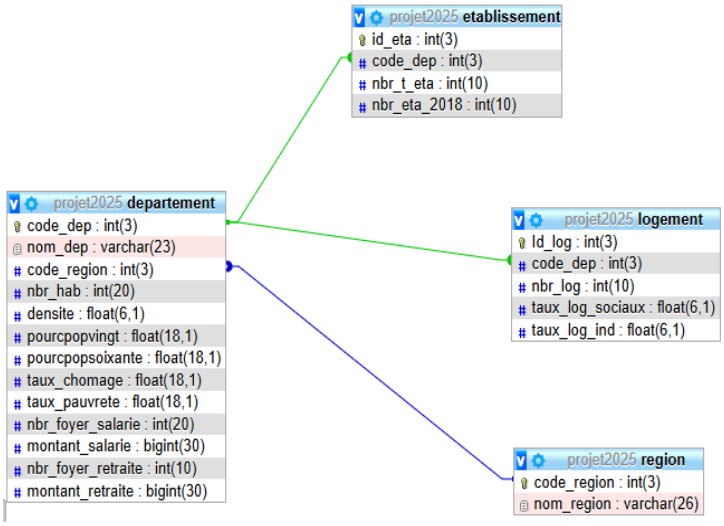

FIGURE 2.2: MOD.

2.4 Import des données

Avant de procéder avec l'importation des données dans PhpMyAdmin, on a effectué un nettoyage des données.

Source de données 1 : Nous avons choisi de nous concentrer uniquement sur les revenus des individus, en distinguant les salariés des retraités. Toutes les colonnes liées aux impôts et aux autres données fiscales ont été supprimées, car elles ne relevaient pas de notre champ d'analyse. Nous avons conservé et renommé uniquement les colonnes décrivant le département (nom et numéro), ainsi que celles indiquant le montant des revenus pour les salariés et les retraités.

Nous avons filtré la colonne « année » afin de ne conserver que les données de l'année 2018. Pour la colonne « code_dep », nous avons supprimé tous les numéros de département précédés d'un zéro et se terminant par un zéro, à l'aide d'une fonction Excel. Par ailleurs, nous avons remplacé les codes des départements de la Corse-du-Sud (2A) et de la Haute-Corse (2B) par les valeurs 96 et 97,afin d'avoir tous les codes de départements en entier. Concernant les colonnes retenues, nous avons nettoyé l'ensemble des données en supprimant les accents, les caractères spéciaux et les majuscules. Nous avons également simplifié les intitulés des en-têtes de colonnes. Pour cela, nous avons utilisé la fonction SUBSTITUTE d'Excel, qui nous a aussi permis de retirer les espaces entre les chiffres dans les colonnes relatives au nombre de foyers et aux montants, afin d'assurer une importation correcte des données au format entier dans MAMP

Source de données 2 : Pour cette étude, nous avons retenu les colonnes relatives au département, à la région d'appartenance, aux données sur les logements (nombre total de logement, part de logements sociaux et individuels), ainsi qu'à divers indicateurs socio-économiques : taux de chômage, taux de pauvreté, densité de population, pourcentage de la population de moins de 20 ans et de 60 ans et plus.

Nous avons trié les départements par ordre alphabétique croissant afin de faciliter la combinaison des deux jeux de données et de créer une seule table intitulée « Departement » dans MAMP. Par ailleurs, le département de Mayotte a été supprimé car il ne figurait pas dans le second jeu de données et les informations le concernant étaient incomplètes. Les colonnes retenues ont ensuite été renommées comme suit : **code_dep, nom_dep, nbr_foyer_salarie, montant_salarie, nbr_foyer_retraite, montant_retraite,code_region, nom_region, nbr_hab, densite,pourcpopvingt,pourcpopsoixante, taux_chomage, taux_pauvrete, nbr_log, taux_log_sociaux, taux_log_individuel**.

Source de données 3 : Pour ce jeu de données, nous avons choisi d'exclure la colonne relative à la part des établissements culturels construits en 2018, l'unité de mesure n'étant pas clairement spécifiée. Il n'était pas possible de déterminer s'il s'agissait d'une valeur monétaire (en euros, milliers ou millions) ce qui aurait pu fausser l'interprétation. Les colonnes retenues ont été renommées comme suit : **id_eta, code_dep, nbr_t_eta, nbr_eta_2018**.

2.5 Requêtes réalisées

```
## Warning: le package 'DBI' a été compilé avec la version R 4.4.3
```

Requête 1 : Lister tous les départements avec leur nom, le nombre d'habitants et le taux de pauvreté

```
SELECT departement.nom_dep,departement.nbr_hab ,departement.taux_pauvrete
from departement
```

Table 2.5: Displaying records 1 - 10

nom_dep	nbr_hab	taux_pauvrete
Ain	643977	11
Aisne	535807	19
Allier	339927	16
Alpes-de-Haute-Provence	161767	17
Hautes-Alpes	141384	14
Alpes-Maritimes	1081455	16
Ardeche	327201	15
Ardennes	273680	20
Ariege	152482	19
Aube	310912	16

Requête 2 : Lister les départements dont nom contient le mot « loire »

```
SELECT departement.code_dep, departement.nom_dep
from departement
where departement.nom_dep LIKE "%loire%"
```

Table 2.6: 7 records

code_dep	nom_dep
37	Indre-et-Loire
42	Loire
43	Haute-Loire
44	Loire-Atlantique
45	Loiret
49	Maine-et-Loire
71	Saone-et-Loire

Requête 3 : Lister les départements avec leur densité qui possèdent un taux de pauvreté inférieur à la moyenne. On affichera les dix premiers départements qui enregistrent le moins de chômage

```sql
SELECT code_dep,nom_dep, densite, taux_pauvrete
FROM departement
WHERE taux_pauvrete < (SELECT AVG(taux_pauvrete) FROM departement)
ORDER BY taux_pauvrete
LIMIT 10;
```

Table 2.7: Displaying records 1 - 10

code_dep	nom_dep	densite	taux_pauvrete
74	Haute-Savoie	186	9.0
85	Vendee	101	10.0
78	Yvelines	628	10.0
44	Loire-Atlantique	215	10.0
73	Savoie	72	10.0
1	Ain	112	11.0
29	Finistere	135	11.0
35	Ille-et-Vilaine	157	11.0
56	Morbihan	110	11.0
21	Cote-d'Or	61	11.5

Requête 4 : Lister les départements avec leur densité qui possèdent un taux de chômage inférieur à la moyenne. On affichera les dix premiers départements qui enregistrent le moins de chômage

```sql
SELECT code_dep,nom_dep, densite, taux_chomage
FROM departement
WHERE taux_chomage < (SELECT AVG(taux_chomage) FROM departement)
ORDER BY taux_chomage
LIMIT 10;
```

Table 2.8: Displaying records 1 - 10

code_dep	nom_dep	densite	taux_chomage
15	Cantal	25	5.0
44	Loire-Atlantique	215	5.5
96	Corse-du-Sud	40	5.8
21	Cote-d'Or	61	5.8
1	Ain	112	6.0
53	Mayenne	59	6.0
74	Haute-Savoie	186	6.0
39	Jura	52	6.0
92	Hauts-de-Seine	9122	6.0
48	Lozere	15	6.0

Les requêtes 3 et 4 fournissent des éléments sur la situation économique des départements, notamment à travers les taux de chômage et de pauvreté. Bien que ces indicateurs soient importants, ils ne suffisent pas à eux seuls à déterminer dans quels départements l'on vit le mieux. Les résultats montrent que les départements ayant les taux de chômage les plus faibles ne sont pas nécessairement ceux où la pauvreté est la moins présente. Certains départements, comme la Côte-d'Or, la Haute-Savoie et l'Ain, présentent toutefois des taux faibles pour ces deux indicateurs.

L'information relative à la densité de population permet également d'apprécier si ces départements sont fortement peuplés ou non. On observe que, mis à part Hauts-Savoie et Yvelines, les départements concernés sont peu ou moyennement peuplés.

Requête 5 : Lister les dix départements français qui présentent la densité de population la plus élevée.

```
SELECT departement.code_dep,departement.nom_dep,departement.densite
FROM departement
ORDER BY departement.densite DESC
LIMIT 10;
```

Table 2.9: Displaying records 1 - 10

code_dep	nom_dep	densite
75	Paris	20780
92	Hauts-de-Seine	9122
93	Seine-Saint-Denis	6900
94	Val-de-Marne	5762
95	Val-d'Oise	997
91	Essonne	721
78	Yvelines	628
69	Rhone	573
59	Nord	455
13	Bouches-du-Rhone	400

Requête 6 : Lister départements avec le montant des revenues des salariés par ordre décroissant.

```
SELECT departement.code_dep,departement.nom_dep,departement.montant_salarie
FROM departement
ORDER BY departement.montant_salarie DESC
```

Table 2.10: Displaying records 1 - 10

code_dep	nom_dep	montant_salarie
75	Paris	43166479210
92	Hauts-de-Seine	29829489811

code_dep	nom_dep	montant_salarie
59	Nord	24599283600
78	Yvelines	23132191421
69	Rhone	22296487843
13	Bouches-du-Rhone	21327075837
94	Val-de-Marne	18572641397
77	Seine-et-Marne	17555206317
33	Gironde	17414630484
91	Essonne	17210174957

Requête 7 : Lister les dix départements les plus peuplés et le revenu des salariés correspondant .On donnera aussi le nombre de logements de ces départements

```
SELECT d.nom_dep, d.nbr_hab, d.montant_salarie, l.nbr_log
FROM departement d
JOIN logement l ON d.code_dep = l.code_dep
ORDER BY d.nbr_hab DESC
LIMIT 10;
```

Table 2.11: Displaying records 1 - 10

nom_dep	nbr_hab	montant_salarie	nbr_log
Nord	2612189	24599283600	1194450
Paris	2181866	43166479210	1366438
Bouches-du-Rhone	2035414	21327075837	1000230
Rhone	1860112	22296487843	890850
Seine-Saint-Denis	1628410	15920780899	652707
Hauts-de-Seine	1605502	29829489811	789809
Gironde	1590570	17414630484	828907
Pas-de-Calais	1474943	12551458646	703500
Loire-Atlantique	1462506	15395217771	776207
Yvelines	1434980	23132191421	621026

L'objectif de cette requête est d'examiner si les départements les plus peuplés c'est-à-dire avec le plus grand nombre d'habitants présentent également un revenu moyen plus élevé ainsi qu'une proportion plus importante de logements que les autres.

Les résultats montrent que le nombre d'habitants n'est pas nécessairement proportionnel au revenu moyen des salariés ni au nombre de logements par département. Par exemple, le département du Nord est plus peuplé que Paris, mais cette dernière compte davantage de logements et affiche un revenu moyen des salariés plus élevé.

Requête 8 : Lister les départements qui possèdent le plus d'établissements culturels

```sql
SELECT d.code_dep, d.nom_dep, e.nbr_t_eta
FROM departement d, etablissement e
WHERE d.code_dep=e.code_dep
ORDER BY nbr_t_eta DESC
LIMIT 10;
```

Table 2.12: Displaying records 1 - 10

code_dep	nom_dep	nbr_t_eta
75	Paris	182079
13	Bouches-du-Rhone	74510
69	Rhone	72720
59	Nord	68081
33	Gironde	59594
92	Hauts-de-Seine	57534
6	Alpes-Maritimes	49039
31	Haute-Garonne	46972
93	Seine-Saint-Denis	46637
44	Loire-Atlantique	45318

Avec cette requête et la 5, on a pu observer que les départements ayant le plus grand nombre d'établissements sont, pour la plupart, ceux ayant la densité la plus élevée.

Requête 9 : Afficher le nombre d'établissement total par region et le nom de la region

```sql
SELECT r.nom_region, SUM(e.nbr_t_eta) AS total_etablissements
FROM region r
JOIN departement d ON r.code_region = d.code_region
JOIN etablissement e ON d.code_dep = e.code_dep
GROUP BY r.nom_region
ORDER BY total_etablissements DESC;
```

Table 2.13: Displaying records 1 - 10

nom_region	total_etablissements
ile-de-france	470619
auvergne-rhone-alpes	287141
nouvelle-aquitaine	216351
occitanie	212823
provence-alpes-cote d'azur	202450
grand est	174773
hauts-de-france	158079
pays de la loire	120335

nom_region	total_etablissements
bretagne	109839
normandie	104304

Cette requête donne une vision globale de l'offre d'infrastructures dans chaque région, ce qui peut être un critère de qualité de vie. Les régions avec plus d'établissements culturels peuvent offrir des conditions de vie plus favorables en termes d'accès à la culture.

Nous pouvons observer que la région Île-de-France regroupe les départements les plus peuplés en termes de densité, ce qui en fait la région avec le plus grand nombre d'infrastructures culturelles.

Requête 10 : Lister dix départements avec les taux de logements sociaux les plus faibles et les revenus des salariés correspondants

```
SELECT d.code_dep,d.nom_dep, l.taux_log_sociaux ,d.montant_salarie
FROM departement d
JOIN logement l ON d.code_dep = l.code_dep
ORDER BY l.taux_log_sociaux ASC
LIMIT 10;
```

Table 2.14: Displaying records 1 - 10

code_dep	nom_dep	taux_log_sociaux	montant_salarie
9	Ariege	5	1157893556
12	Aveyron	6	2200576943
32	Gers	6	1575089365
46	Lot	6	1335539711
24	Dordogne	7	3143389291
40	Landes	7	3686812472
47	Lot-et-Garonne	7	2667465826
48	Lozere	8	586070966
19	Correze	8	2018605916
43	Haute-Loire	8	1928086321

Cette requête nous permet de voir que les départements présentant les taux de logements sociaux les plus faibles ne sont pas forcément ceux ayant les revenus les plus élevés, comme on pourrait le croire. Au contraire, par exemple, des départements comme la Lozère, l'Ariège et le Lot sont des départements ayant à la fois les revenus salariaux les plus bas et les taux de logements sociaux les plus faibles.

Chapitre 3

Matériel et Méthodes

3.1 Logiciels

Pour faciliter les échanges tout au long du projet, nous avons utilisé le logiciel Google Docs avec un dossier partagé, dans lequel chacune avançait sur sa partie.

Pour travailler et communiquer en temps réel, nous avons également utilisé l'application WhatsApp ainsi que les adresses mail de l'université afin de nous transmettre, à tour de rôle, chaque nouvelle modification apportée.

Le logiciel Excel nous a permis de supprimer les colonnes inutiles, de nettoyer les données comme évoqué dans la partie sur l'importation des données et de créer différentes feuilles correspondant aux tables.

Grâce à l'outil open-source MOCODO, nous avons pu créer le Modèle Conceptuel de Données(MCD). Et ensuite avec l'application MAMP, via l'interface PhpMyAdmin, nous avons créer le Modèle Organisationnel de Données (MOD) et manipuler nos données pour réaliser les requêtes nécessaires.

Nous avons ensuite utilisé le logiciel R, à travers son interface RStudio, pour effectuer des analyses statistiques, produire des graphiques, établir une connexion directe avec notre base de données, et générer un rapport complet au format PDF à l'aide de R Markdown.

Enfin, nous avons eu recours à l'outil d'intelligence artificielle générative ChatGPT pour la correction orthographique ainsi que pour l'amélioration rédactionnelle de l'ensemble du rapport.Tout en précisant qu'on ne lui a pas demandé de nous générer directement du texte, ce sont nos propres textes qu'il a juste corrigé.

Les analyses ont été réalisées sur un ordinateur fonctionnant sous Windows 11, équipé d'un processeur Intel Core i7-1065G7 cadencé à 1,30 GHz, de 32 Go de mémoire vive, d'un stockage de 512 Go et d'une carte graphique Intel Iris Plus Graphics.

3.2 Modélisation statistique

Pour les analyses des relations entre nos variables nous avons utilisé le logiciel R Markdown.

Nous avons utilisé deux outils fondamentaux : le test de corrélation de Pearson et l'analyse de variance (ANOVA).

3.2.1 Le test de corrélation de Pearson

Ce test évalue l'intensité et le signe d'une relation linéaire entre deux variables quantitatives.

Pour son utilisation dans R on a utilisé la fonction cor() pour le simple calcul et cor.test() pour effectuer le test de corrélation.

$$r = \frac{Cov(X, Y)}{\sigma(X) \cdot \sigma(Y)}$$

3.2.2 Analyse de la variance

L'ANOVA est utilisé pour comparer les moyennes de plusieurs groupes et se base sur la décomposition de la variance totale en ses deux composantes : la variance INTER et la variance INTRA.

La statistique de test pour le test d'ANOVA peut s'écrire :

$$\frac{INTER}{INTRA}(n - K)$$

$n =$ effectifs et $K =$ nombre de groupes

Pour effectuer le test d'ANOVA sur R on a utilisé la fonction aov().

Chapitre 4

Analyse Exploratoire des Données

Après avoir importé les fichiers (Departement.csv, Etablissement.csv, Logement.csv) contenant nos données, on a pu coder les types des variables de notre jeu de données (codes en annexe). Avec ceci on a créé des data frames pour mieux traiter les données.

4.1 Import des fichiers csv utiles aux analyses statistiques

```
## Warning: le package 'ggplot2' a été compilé avec la version R 4.4.3
## L'objet suivant est masqué depuis departement:
##
##     code_dep
```

Voici la nature des variables utilisées :

- montant_salarie : variable quantitative continue
- taux_chomage : variable quantitative continue
- taux_chomage : variable quantitative continue
- taux_log_sociax : variable quantitative continue
- nbr_t_eta : variable quantitative discrète

```
## L'objet suivant est masqué depuis etablissement:
##
##     code_dep
## L'objet suivant est masqué depuis departement:
##
##     code_dep
```

4.2 Analyses univariées

On considère d'abord la variable **nombre d'habitants par départements**. Pour mieux la visualiser la représente à l'aide d'un histogramme.

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

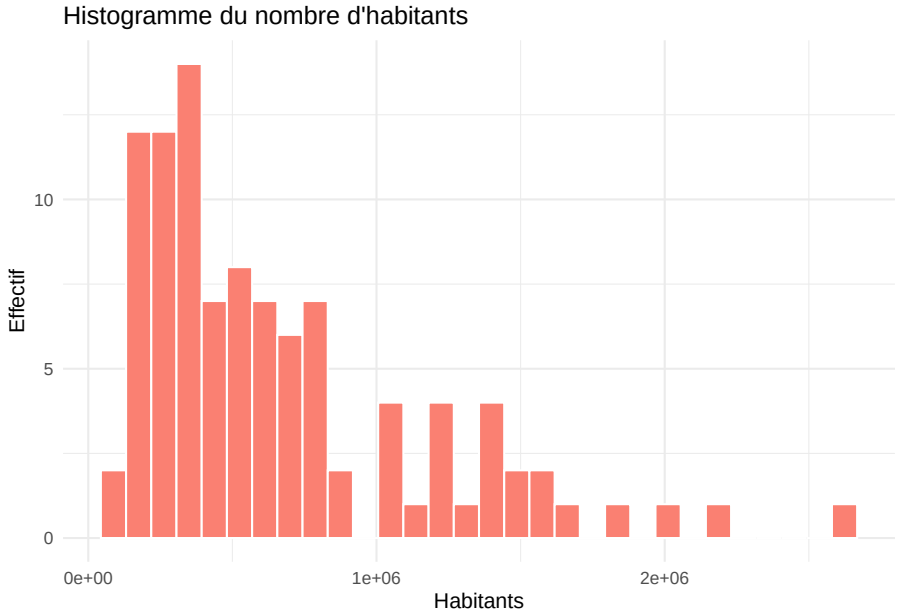

On remarque une grande disparité dans la répartition du nombre d'habitants par département, comme on peut le voir avec certains départements très peuplés et d'autres n'enregistrant que peu d'habitants.

On calcule la moyenne globale :

```
## [1] 668516.3
```

On calcule la mediane globale :

```
## [1] 534985.5
```

Maintenant on va considérer la variable **nombre de logements par départements**. Comme pour la variable précédente on va la représenter grâce à un histogramme.

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

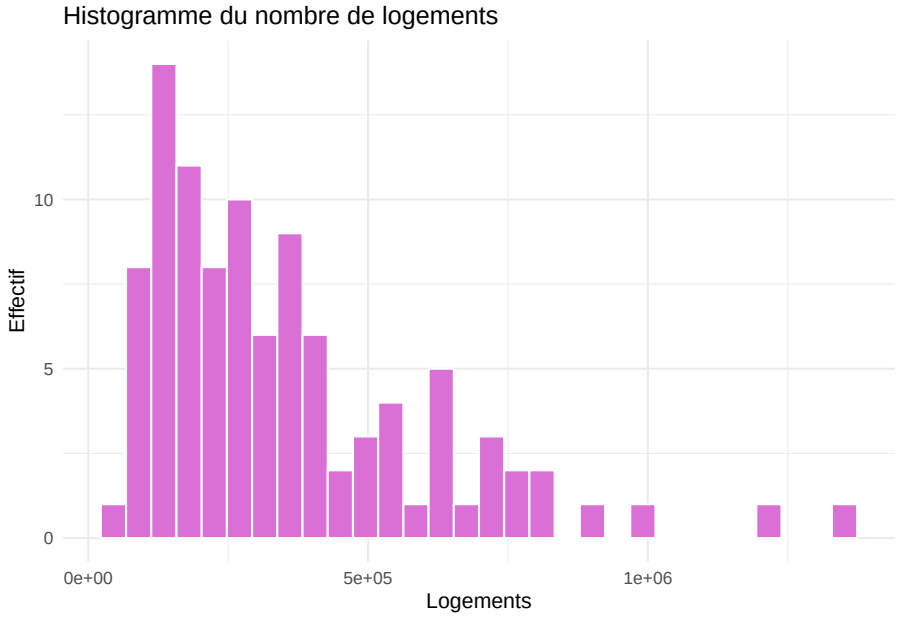

On constate une grande disparité dans la répartition du nombre de logements par département, comme on peut le voir avec certains départements ayant de nombreux logements et d'autres n'enregistrant que peu de logements.

Selon notre hypothèse, les disparités importantes pourraient être dû au fait qu'un département plus peuplé ait plus de logements qu'un département moins peuplé. On va vérifier cela dans la partie suivante de l'analyse bivariée.

4.3 Analyses bivariées

On commence par analyser la relation entre les **variables montant salaire et le taux de chômage**. Afin de mieux visualiser un lien éventuel entre les variables, on représente le nuage de points des variables montant_salaire et taux_chomage :

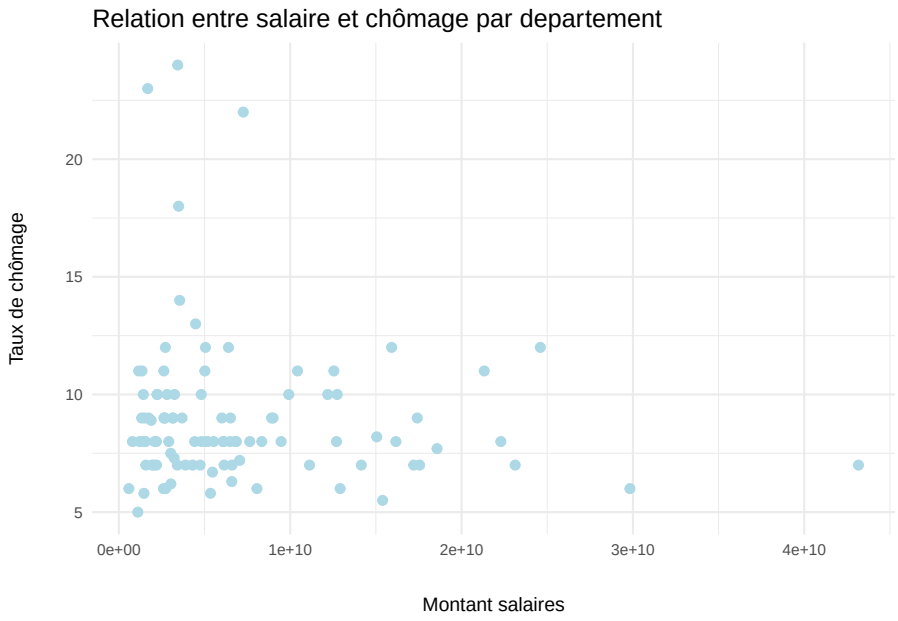

On observe un nuage de points très dispersé, avec cinq points particulièrement éloignés des autres. Il ne semble pas y avoir de lien entre le montant des salaires générés par département et le taux de chômage.

A partir du nuage de points on peut supposer que entre les deux variables il n'y a pas de liaison, on calcule donc le coefficient de corrélation :

Après le calcul on obtient le coefficient de corrélation :

```
## [1] -0.1009249
```

Ce résultat montre une corrélation inverse faible entre les deux variables. Pour approfondir notre analyse, on passe au test de corrélation entre les deux variables.

Hypothèse H : les variables montant_salaire et taux_chomage ne sont pas corrélées On procède avec le test à l'aide de la fonction cor.test sur R, qui nous fournit tous les détailles :

```
##
##  Pearson's product-moment correlation
##
## data:  departement$montant_salarie and departement$taux_chomage
## t = -1.0042, df = 98, p-value = 0.3177
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.29156323  0.09742451
## sample estimates:
##        cor
## -0.1009249
```

Le résultat nous indique une relation linéaire non significative entre les variables montant salaire et taux chômage avec un coefficient de corrélation r = -0.10.

La co-valeure 0.3177 est inférieure à 0.05, cela implique qu' avec un niveau de confiance de 95%, on ne peut rejeter l'hypothèse H.

Il n'existe donc aucune association linéaire significative entre le montant des salaires par département et le taux de chômage. On en déduit que les salaires n'ont pas d'influence sur le taux de chômage.

Il est aussi intéressant de voir si les variables **montant_salaire et taux_pauvrete** sont corrélées. Voici le nuage des points des deux variables :

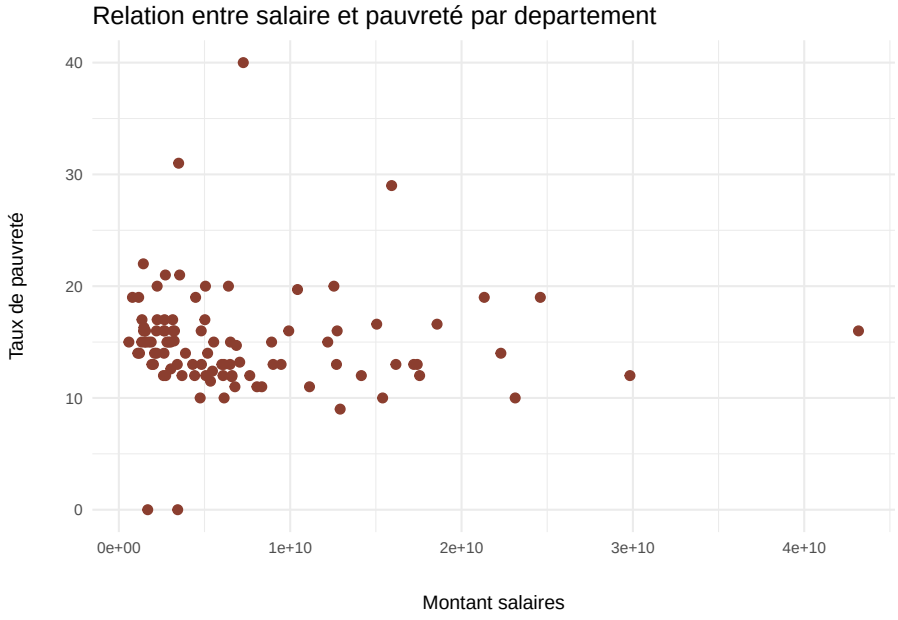

On observe un nuage de points un peu plus condensé, avec également cinq points qui restent quelque peu isolés par rapport aux autres.

A partir du nuage des points il semble qu'il n'y ait pas de lien entre le montant des salaires générés par département et le taux de pauvreté dans ces départements.

On calcule donc le coefficient de corrélation :

```
## [1] -0.01538043
```

Ce résultat montre une corrélation inverse très faible entre les deux variables.

Comme avant on procède au test de corrélation entre ces variables :

Hypothèse H : les variables montant_salaire et taux_pauvrete ne sont pas corrélés.

Voici les résultats du test en détail :

```
##
##  Pearson's product-moment correlation
##
## data:  departement$montant_salarie and departement$taux_pauvrete
## t = -0.15228, df = 98, p-value = 0.8793
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.2111606  0.1815863
## sample estimates:
##         cor
## -0.01538043
```

On a bien confirmé que il y a une relation linéaire non significative entre les variables montant_salaire et taux_pauvrete, avec un coefficient de corrélation r=-0.015

La p-valeure de 0.8793 est largement supérieure à 0.05, cela implique qu'avec un niveau de confiance de 95%, on ne peut pas rejeter l'hypothèse H.

Il n'existe donc aucune association linéaire significative entre le montant des salaires par département et le taux de pauvreté. On en déduit que les salaires n'ont pas d'influence sur le taux de pauvreté.

On passe finalement à l'analyse des relations entre les variables **nbr_t_eta et t_log_soc** : Voici le nuage des points :

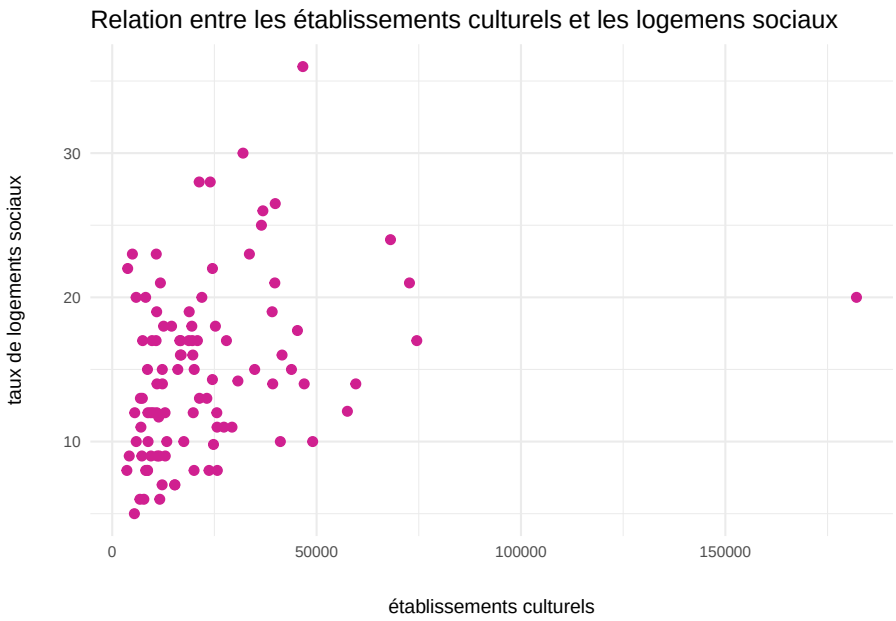

On observe un nuage de points légèrement éparpillé, avec un point atypique particulièrement éloigné des autres. On pourrait supposer l'existence d'un lien positif faible entre les deux variables. Toutefois, il est également possible qu'il n'existe aucun lien entre le nombre d'établissements culturels et le taux de logements sociaux dans un département.

Pour vérifier cela on calcule le coefficient de corrélation :

```
## [1] 0.3083597
```

Le résultat nous montre une corrélation faible positive entre les deux variables.

On passe au test de corrélation pour mieux analyser ce lien.

Hypothèse H : les variables nombre d'établissements culturels et taux de logements sociaux ne sont pas corrélées.

On procède avec le test avec la fonction cor.test pour plus de détails :

```
##
##  Pearson's product-moment correlation
##
## data:  etablissement$nbr_t_eta and logement$t_log_soc
## t = 3.209, df = 98, p-value = 0.001801
```

```
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.1191588 0.4759507
## sample estimates:
##       cor
## 0.3083597
```

Le résultat nous suggère une relation linéaire positive entre entre les variables nombre d'établissements culturels et taux de logements sociaux, avec un coefficient de corrélation r = 0.31.

La p-valeur de 0.0018 est bien inférieure à 0.05, ce qui implique qu'avec un niveau de confiance de 95%, on peut rejeter l'hypothèse H et conclure qu'il existe une corrélation significative entre les deux variables.

Il existe donc une association linéaire positive entre le nombre d'établissements culturels et le taux de logements sociaux par département. Les résultats suggèrent que les départements ayant davantage d'établissements culturels tendent également à avoir un taux de logements sociaux plus élevé.

4.4 Test d'ANOVA

Nous souhaitons étudier si le revenu par classe a un effet significatif sur le nombre d'établissements culturels par département. Pour cela nous avons réalisé un test d'ANOVA (analyse de variance à un facteur).

Les données concernant la variable montant_salaire ont été classées en quatre catégories (selon les quartiles) afin de les transformer en une variable qualitative ordinale catégorie de revenu avec 4 modalités : **faible, moyen-faible, moyen-élevé et élevé**.

L'objectif de cette analyse est de déterminer si le niveau de revenu d'un département (catégorie de revenu) a un impact significatif sur le nombre d'établissements culturels présents sur son territoire.

Nous utilisons donc un test d'ANOVA à un facteur pour répondre à cette question.

Hypothèse : Les revenus par classe n'ont pas d'impact sur la distribution du nombre total d'établissements culturels dans chaque département.

Nous avons appliqué le test d'ANOVA pour comparer les moyennes du nombre d'établissements culturels entre ces groupes :

```
##                  Df    Sum Sq   Mean Sq F value   Pr(>F)
## categorie_revenu  3 2.626e+10 8.752e+09   35.94 1.17e-15 ***
## Residuals        96 2.338e+10 2.435e+08
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

La statistique de test F est calculée comme le rapport de la variance inter-groupes a la variance intra-groupes. ici F=234.4 qui indique une variabilité entre groupes supérieure à celle à l'intérieur des groupes. En plus la p-valeur associée est extrêmement faible (1.1710⁻15), bien inférieure au seuil de 0.05.

Puisque la p-valeur est très inférieure à 0.05, on rejette l'hypothèse. On peut donc dire qu'il existe une difference tres significative du nombre moyen d'établissement culturels selon la catégorie de revenu.

Le revenu a donc un effet et sur le nombre d'établissements culturels.

Visualisons avec un box-plot le nombre d'établissements culturels par catégorie de revenu.

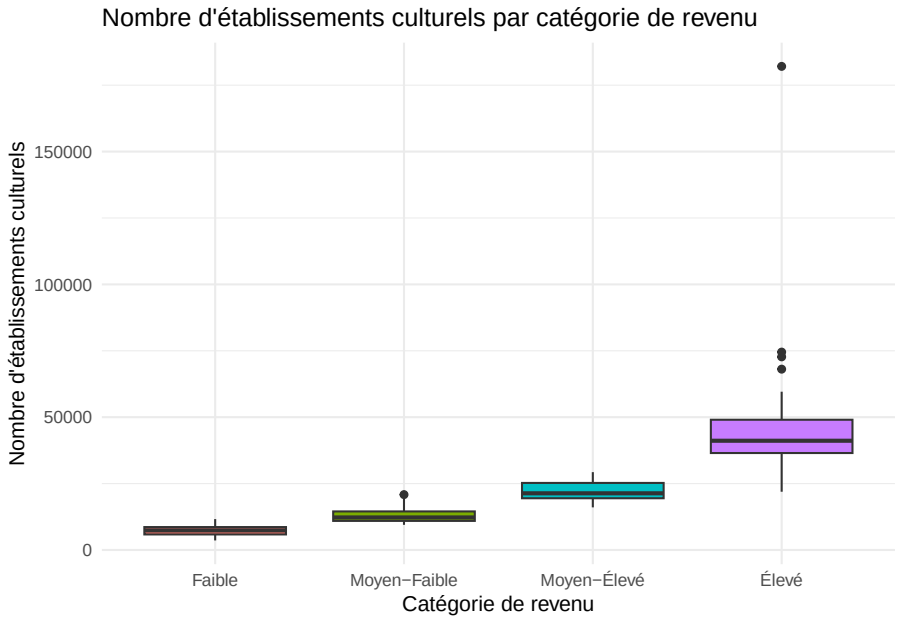

FIGURE 4.1: Nombre d'établissements culturels par catégorie de revenu

Le boxplot du nombre d'établissements culturels par catégorie de revenu montre visuellement que : le nombre d'établissements augmente nettement avec la catégorie de revenu.

La médiane et la dispersion sont plus élevées dans les groupes à revenu élevé.

En conclusion, le test d'ANOVA montre que **le revenu moyen d'un département à un effet significatif sur le nombre d'établissements culturels**.

Chapitre 5

Discussion

Notre analyse a relevé une absence de corrélation significative entre le montant des salaires et le taux de chômage, ainsi qu'entre le montant des salaires et le taux de pauvreté. Ces résultats contredisent l'hypothèse selon laquelle les départements aux revenus plus élevés offraient nécessairement de meilleures conditions de vie. En effet, certains départements comme Paris ou les Hauts-de-Seine présentent des revenus parmi les plus élevés, mais cela ne se traduit pas automatiquement par des taux de chômage ou de pauvreté plus faibles.

L'absence de corrélation suggère que d'autres facteurs influencent la qualité de vie dans les départements. Par exemple, le coût de la vie ou le prix de l'immobilier,etc.

En revanche, le test d'ANOVA a démontré une relation significative entre le niveau de revenu d'un département et le nombre d'établissements culturels. Le boxplot illustre clairement que les départements à revenus élevés disposent en moyenne davantage d'établissements culturels. Cette partie de notre hypothèse initiale se trouve donc confirmée : les départements économiquement plus favorisés offrent effectivement un accès plus important à la culture.

Cependant cette relation mérite d'être nuancée.La présence d'infrastructures culturelles pourrait être davantage liée à la densité de la population qu'au revenu en lui- même. Nos requêtes SQL ont montré que les départements avec le plus d'établissements culturels correspondent en grand partie à ceux ayant les densités de population les plus élevées.

Contrairement à notre hypothèse initiale, l'analyse montre une corrélation positive significative entre le nombre d'établissements culturels et le taux de logements sociaux. Ainsi les départements disposant de nombreuses infrastructures culturelles tendent également à avoir une proportion plus importante de logements sociaux, ce qui va à l'encontre de l'idée que les départements offrant les meilleures conditions de vie auraient moins de logements sociaux.

Chapitre 6

Conclusion

Cette étude a permis d'explorer la question des meilleures conditions de vie dans les départements français, en les liant à des critères tels que les revenus moyens, l'accès aux infrastructures culturelles, et la proportion de logements sociaux. Les résultats ont remis en cause l'idée selon laquelle les départements avec les revenus les plus élevés sont automatiquement ceux offrant les meilleures conditions de vie. Des départements comme la Haute-Savoie, la Vendée, et les Yvelines illustrent que des faibles taux de pauvreté et un accès à des infrastructures culturelles variées peuvent contribuer à des conditions de vie de qualité, même si leurs revenus ne sont pas toujours les plus élevés. À l'inverse, des départements comme Paris ou les Hauts-de-Seine, bien que riches, ne garantissent pas nécessairement des conditions de vie plus favorables, notamment à cause des inégalités sociales et de l'accès limité à certains services publics. Les résultats ont également montré que les départements à faibles taux de chômage, tels que l'Ain, l'Aveyron, ou le Calvados, bien qu'économiquement moins dynamiques, peuvent offrir une qualité de vie comparable à celle de départements plus riches. Cela suggère que des facteurs sociaux et culturels, comme l'accès à la culture et à des logements sociaux, jouent un rôle tout aussi important que le revenu dans la définition des conditions de vie. En conclusion, cette étude met en lumière l'importance d'une approche multidimensionnelle pour évaluer les conditions de vie dans les départements français. Il est clair que les revenus ne sont pas le seul facteur déterminant. Des départements avec un revenu moyen plus bas peuvent offrir une meilleure qualité de vie grâce à une gestion plus équilibrée de l'accès au logement, à la culture et à la réduction des inégalités sociales. Pour évaluer réellement les conditions de vie, il est nécessaire de prendre en compte l'ensemble de ces facteurs, et non de se concentrer uniquement sur les indicateurs économiques.

6.1 Perspectives

Pour améliorer rapidement notre approche de l'évaluation de la qualité de vie, il serait judicieux d'élargir le nombre d'indicateurs utilisés. En complément du revenu moyen, du taux de logements sociaux, d'établissements culturels, du taux de pauvreté, du taux de chômage l'intégration de facteurs comme l'espérance de vie, le taux de criminalité, la qualité de l'air, le coût de la vie et le prix de l'immobilier permettrait d'obtenir une vision plus complète et précise des conditions de vie dans les départements français.

À plus long terme, il serait intéressant de construire un indice composite de qualité de vie basé sur une pondération de différents critères sociaux, économiques et environnementaux. D'un point de vue "science des données", cela pourrait impliquer l'utilisation de techniques de machine learning non supervisées (ex : clustering) pour identifier naturellement des groupes de départements ayant des profils de qualité de vie similaires et des critères spécifiques aux demandeurs pour identifier le département le plus adéquat à leur attente. Enfin cette analyse pourrait être utilisée pour guider les politiques publiques d'aménagement du territoire, en ciblant mieux les investissements dans les infrastructures sociales, culturelles et environnementales.

6.2 Difficultés

Nous avons rencontré quelques difficultés notamment lors de l'importation des données dans PhpMyAdmin, nous avons rencontré de nombreuses erreurs. Il a été nécessaire d'effectuer plusieurs modifications dans Excel : suppression des accents, réduction du nombre de décimales après la virgule et suppression des espaces entre les chiffres afin d'éviter leur interprétation comme des chaînes de caractères. Malgré ces ajustements, certaines erreurs persistaient sans explication claire pour certaines d'entre nous , tandis que d'autres tables s'importaient correctement chez d'autres.

Nous avons également été confrontées à un problème de correspondance des années entre nos différentes sources de données. La première source de données sur les revenus couvraient la période 2000-2017, tandis que la deuxième source de données sur leslogements et logements sociaux concernaient les années 2018-2023. Pour assurer la cohérence de la table **Departement**, nous avons retenu, pour chaque source de donné, la dernière année disponible. L'analyse des évolutions d'une année sur l'autre a montré des écarts faibles, ce qui nous a permis d'estimer que les données de 2017 et 2018 étaient suffisamment proches pour être combinées.

Bibliographie

https://biostatisticien.eu/springeR/livreR.pdf

https://www.scribbr.com/statistics/anova-in-r/

https://louernos-nature.fr/test-correlation-statistique-langage-r/
perplexity.ai

Annexes

```r
#install.packages(c("sf", "ggplot2", "dplyr"))
library(sf)
```

```
## Warning: le package 'sf' a été compilé avec la version R 4.4.3
## Linking to GEOS 3.13.0, GDAL 3.10.1, PROJ 9.5.1; sf_use_s2() is TRUE
```

```r
library(ggplot2)
library(dplyr)
```

```
## Warning: le package 'dplyr' a été compilé avec la version R 4.4.3
##
## Attachement du package : 'dplyr'
## Les objets suivants sont masqués depuis 'package:stats':
##
##     filter, lag
## Les objets suivants sont masqués depuis 'package:base':
##
##     intersect, setdiff, setequal, union
```

```r
departement <- st_read("https://raw.githubusercontent.com/codeforamerica/click_
```

```
## Reading layer `france-departments' from data source
##   `https://raw.githubusercontent.com/codeforamerica/click_that_hood/master/p
##   using driver `GeoJSON'
## Simple feature collection with 96 features and 5 fields
## Geometry type: MULTIPOLYGON
## Dimension:     XY
## Bounding box:  xmin: -5.139017 ymin: 41.36276 xmax: 9.559823 ymax: 51.089
## Geodetic CRS:  WGS 84
```

```r
set.seed(42)
departement$montant_sa <- sample(50000000:30000000000, nrow(departement), repla

ggplot(departement) +
  geom_sf(aes(fill = montant_sa)) +
  scale_fill_viridis_c(option = "plasma", trans = "log", name = "Montant salai
  labs(
    title = "Montant salaire par département en France"
  ) +
```

```r
  theme_minimal() +
  theme(legend.position = "right")
```

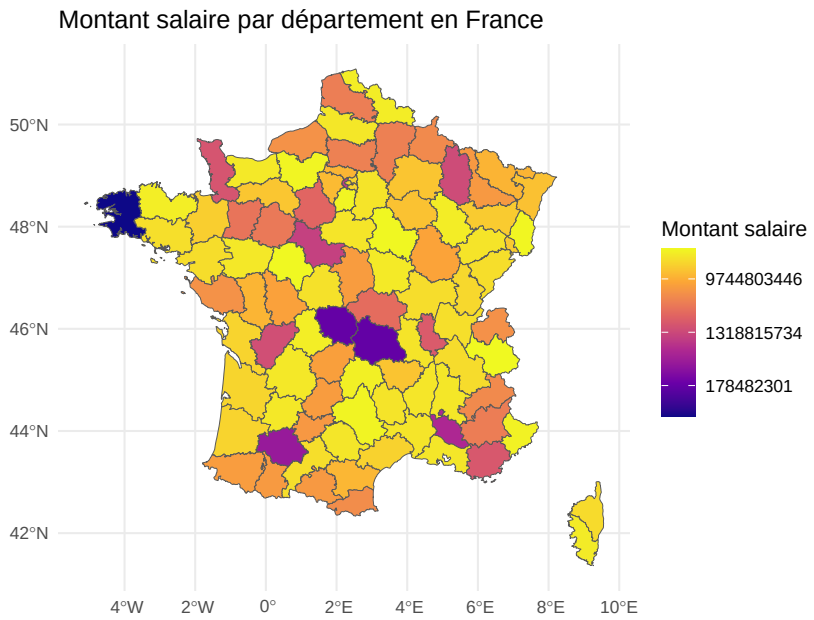

Codes

```{r,echo= FALSE}
library(ggplot2)

departement <- read.csv("Departement.csv", header = T)
departement <- as.data.frame(departement)

attach(departement)

#head(departement)

#variables qualitatives nominales

departement$code_dep <- as.factor(departement$code_dep)
#dans ce cas la variable code_dep est une variable qualitative nominale,
#même chose pour code_region
departement$nom_dep <- as.factor(departement$nom_dep)
departement$code_region <- as.factor(departement$code_region)

#variables quantitatives discrètes

departement$nbr_hab <- as.integer(departement$nbr_hab)
departement$nbr_foyer_salarie <- as.integer(departement$nbr_foyer_salarie)
departement$nbr_foyer_retraite <- as.integer(departement$nbr_foyer_retraite)

#variables quantitatives continues
#departement$densité <- as.double(departement$densité)

departement$pourcpopvingt <- as.double(departement$pourcpopvingt)
departement$pourpopsoixante <- as.double(departement$pourpopsoixante)
departement$taux_chomage <- as.double(departement$taux_chomage)
departement$taux_pauvrete <- as.double(departement$taux_pauvrete)
departement$montant_salarie <- as.double(departement$montant_salarie)
departement$montant_retraite <-as.double(departement$montant_retraite)

```

FIGURE 6.1: Code de la nature des variables dans la table Departement.

```{r,echo= FALSE}
library(ggplot2)

etablissement <- read.csv("Etablissement.csv", header = T)
etablissement <- as.data.frame(etablissement)

attach(etablissement)

#variables qualitatives nominales

etablissement$id_eta <- as.factor(etablissement$id_eta)
etablissement$code_dep <- as.factor(etablissement$code_dep)

#variables quantitatives discrètes

etablissement$nbr_t_eta <- as.integer(etablissement$nbr_t_eta)
etablissement$nbr_eta_2018 <- as.integer(etablissement$nbr_eta_2018)
```

FIGURE 6.2: Code de la nature des variables dans la table Etablissement.

```{r,echo= FALSE}
library(ggplot2)

logement <- read.csv("Logement.csv", header = T)
logement <- as.data.frame(logement)

attach(logement)

#variables qualitatives nominales

logement$Id_log <- as.factor(logement$Id_log)
logement$code_dep <- as.factor(logement$code_dep)

#variables quantitatives discrètes

logement$nbr_log <- as.integer(logement$nbr_log)

#variables quantitatives continues

logement$t_log_soc <- as.double(logement$t_log_soc)
logement$t_log_indiv <- as.double(logement$t_log_indiv)
```

FIGURE 6.3: Code de la nature des variables dans la table Logement.

```{r, out.width= "12cm", fig.align= "center",echo= FALSE}
ggplot(departement, aes(x = nbr_hab)) +
  geom_histogram(fill = "salmon", color = "white") +
  labs(title = "Histogramme du nombre d'habitants", x = "Habitants", y = "Effectif") +
  theme_minimal()

```

FIGURE 6.4: Code de l'histogramme du nombre d'habitants par département(nbr_hab).

```{r, out.width= "12cm", fig.align= "center",echo= FALSE}
ggplot(logement, aes(x = nbr_log)) +
  geom_histogram(fill = "orchid", color = "white") +
  labs(title = "Histogramme du nombre de logements", x = "Logements", y = "Effectif") +
  theme_minimal()

```

FIGURE 6.5: Code de l'histogramme du nombre de logements par département(nbr_log).

```{r, out.width= "12cm", fig.align= "center",echo=FALSE}
#revenu et taux chomage
data<- departement

library(ggplot2)

nuage1<-ggplot(data, aes(x = montant_salarie, y = taux_chomage)) +

  geom_point(color="lightblue",size=2) +

  labs(x = "Montant salaires", y = "Taux de chômage", title = "Relation entre salaire et chômage par
departement") +

  theme_minimal()+

  theme(axis.title.y = element_text(margin = margin(r = 20),size=10),
        axis.title.x = element_text(margin = margin(t=20),size=10),
        legend.position = "none",
        axis.text.y = element_text( size = 8),
        axis.text.x = element_text( size = 8),
        #plot.background = element_rect(color = "grey", fill = NA, size = 1),
        #plot.margin = margin(t = 20, r = 20, b = 20, l = 20, unit = "pt")
        )
nuage1

```

FIGURE 6.6: Code du nuage de points entre les revenu des salaires et le taux de chômage .

```{r, out.width= "12cm", fig.align= "center",echo=FALSE}
#revenu et taux pauvrete
data<- departement

nuage1<-ggplot(data, aes(x = montant_salarie, y = taux_pauvrete)) +

  geom_point(color="coral4",size=2) +

  labs(x = "Montant salaires", y = "Taux de pauvreté", title = "Relation entre salaire et pauvreté par departement") +

  theme_minimal()+

  theme(axis.title.y = element_text(margin = margin(r = 20),size=10),
        axis.title.x = element_text(margin = margin(t=20),size=10),
        legend.position = "none",
        axis.text.y = element_text( size = 8),
        axis.text.x = element_text( size = 8),
        #plot.background = element_rect(color = "grey", fill = NA, size = 1),
        #plot.margin = margin(t = 20, r = 20, b = 20, l = 20, unit = "pt")
        )
nuage1

```

FIGURE 6.7: Code du nuage de points entre les revenu des salaires et le taux de pauvreté .

```{r, out.width= "12cm", fig.align= "center",echo=FALSE}
#établissement et logements sociaux
data<- etablissement
data<- logement

nuage1<-ggplot(data, aes(x = nbr_t_eta, y = t_log_soc)) +

  geom_point(color="violetred",size=2) +

  labs(x = "établissements culturels", y = "taux de logements sociaux", title = "Relation entre les établissements culturels et les logemens sociaux") +

  theme_minimal()+

  theme(axis.title.y = element_text(margin = margin(r = 20),size=10),
        axis.title.x = element_text(margin = margin(t=20),size=10),
        legend.position = "none",
        axis.text.y = element_text( size = 8),
        axis.text.x = element_text( size = 8),
        #plot.background = element_rect(color = "grey", fill = NA, size = 1),
        #plot.margin = margin(t = 20, r = 20, b = 20, l = 20, unit = "pt")
        )
nuage1

```

FIGURE 6.8: Code du nuage de points entre le taux de logements sociaux et le nombre total d'établissement .

```{r,echo=FALSE}
cor(departement$montant_salarie, departement$taux_chomage, method="pearson")
```

FIGURE 6.9: Code d'un exemple de coefficient de corrélation .

```{r,echo=FALSE}
cor.test(departement$montant_salarie, departement$taux_chomage, method="pearson")
```

FIGURE 6.10: Code d'un exemple de test de corrélation .

```{r ,fig.align= "center",echo=FALSE}
donnees_fusionnees <- merge(departement, etablissement, by = "code_dep")

# Division en quartiles pour créer 4 catégories de revenu
donnees_fusionnees$categorie_revenu <- cut(donnees_fusionnees$montant_salarie,
                                           breaks = quantile(donnees_fusionnees$montant_salarie,
                                                             probs = seq(0, 1, 0.25),
                                                             na.rm = TRUE),
                                           labels = c("Faible", "Moyen-Faible", "Moyen-Élevé", "Élevé"),
                                           include.lowest = TRUE)

anova <- aov(nbr_t_eta ~ categorie_revenu, data = donnees_fusionnees)

summary(anova)

```

FIGURE 6.11: Code du test d'ANOVA .

```{r, fig.cap = "Nombre d'établissements culturels par catégorie de revenu",out.width= "12cm",
fig.align= "center",echo=FALSE}
#visualisation avec boxplot

library(ggplot2)
ggplot(donnees_fusionnees, aes(x = categorie_revenu, y = nbr_t_eta, fill = categorie_revenu)) +
  geom_boxplot() +
  labs(title = "Nombre d'établissements culturels par catégorie de revenu",
       x = "Catégorie de revenu",
       y = "Nombre d'établissements culturels") +
  theme_minimal() +
  theme(legend.position = "none")


```

FIGURE 6.12: Code du box-plot.